



Big Data + Data Mining

Beer & Diapers

01

Etapas



Etapas

1. Determinación de las fuentes de los datos.

- Capturar/Extraer los datos. ¿Qué está disponible?
- Almacenar los datos.



Etapas

1. Determinación de las fuentes de los datos.

- Capturar/Extraer los datos. ¿Qué está disponible?
- Almacenar los datos.

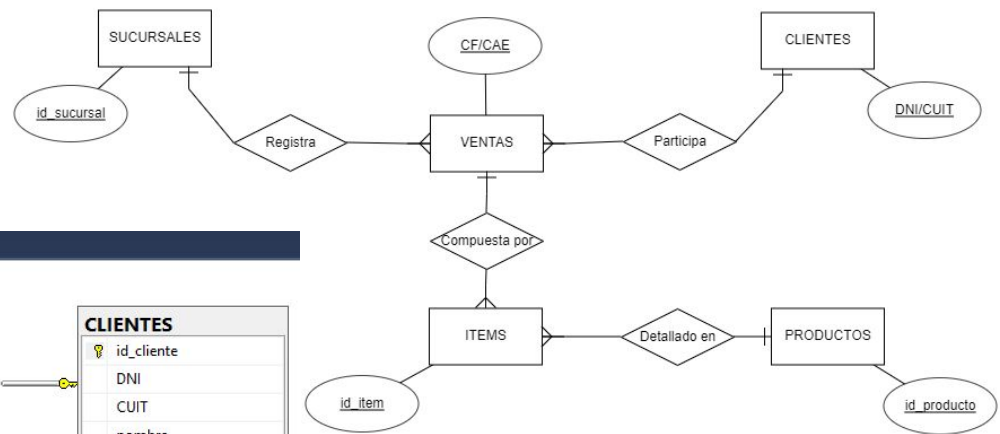
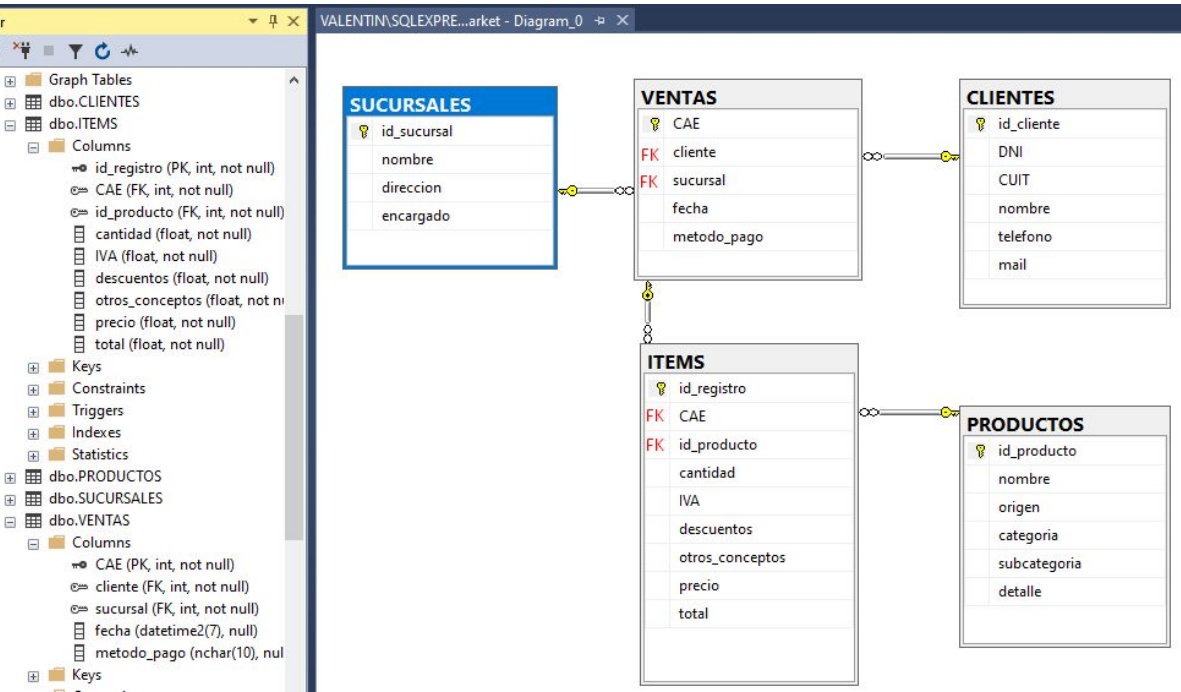
2. Exploración y pre-procesado de los datos → Prepararlos.

- Investigación preliminar de los datos para comprender sus características.
- Limpiar los datos para obtener un conjunto de datos de calidad.
- Manipular los datos para que estén en el formato necesario para su posterior uso.



(1y2) DB del Big Data: Datos Estructurados

Ejemplo de una posible Base de Datos en Microsoft SQL Server y su respectivo Diagrama de Entidad Relación.



(1y2) DB del Big Data: Datos No Estructurados

Ejemplo de una posible Base de Datos en NoSQL MongoDB Atlas (Cloud Database) y la mock data creada con Mockaroo.

The image displays two side-by-side screenshots. The left screenshot shows the Mockaroo interface, which is used for generating mock data. It features a sidebar with navigation options like 'DEVELOP', 'Databases', 'Data Lake', 'DATA', 'Triggers', 'Data API', 'SECURITY', 'Database', 'Network', and 'Advance'. The main area shows a schema for a database with various fields and their types, including CF, IBAN, fecha, hora, sucursal.id, sucursal.nombre, sucursal.direccion, sucursal.ciudad, cliente.DNI, cliente.nombre, cliente.mail, items, items.productos, items.cantidad, items.precio, and items.descuento. Each field has a dropdown menu to select its type (e.g., Number, String, Date, Time, JSON Array) and a set of icons to configure its properties (e.g., min, max, format, blank, %).

The right screenshot shows the MongoDB Atlas interface, displaying a collection of mock data. The data is structured as a JSON array of objects, each representing a record. The records contain fields like 'CF', 'fecha', 'hora', 'sucursal', 'cliente', and 'items'. The 'sucursal' field is an object with 'id', 'nombre', 'direccion', and 'ciudad'. The 'cliente' field is an object with 'DNI', 'nombre', and 'mail'. The 'items' field is an array of objects, each representing a product with 'productos', 'cantidad', 'precio', and 'descuento'.

```
[{"CF": "HRS1 1782 5879 3643 8095 1924 278", "fecha": "26/05/2021", "hora": "8:25", "sucursal": {"id": 49, "nombre": "Yabon", "direccion": "9693 Hollow Ridge Street", "ciudad": "Tan-Tan"}, "cliente": {"DNI": "58077008", "nombre": "Cories Alabone", "mail": "calabone2@canalblog.com"}, "items": [{"productos": "Wine - Sauvignon Blanc Oyster", "cantidad": 4, "precio": "$262.11", "descuento": null}, {"productos": "Paste - Black Olive", "cantidad": 73, "precio": "$222.95", "descuento": null}], "CF": "EL15 5558 5300 8869 3288 5975 2589", "fecha": "27/05/2021", "hora": "11:09", "sucursal": {"id": 6, "nombre": "Skimia", "direccion": "3 Mendota Drive", "ciudad": "Sherpur"}, "cliente": {"DNI": "84429769", "nombre": "Worthington Robker", "mail": "wrobker3@storify.com"}, "items": [{"productos": "Flour - Rye", "cantidad": 1, "precio": "$15.58", "descuento": null}]}]
```

(1y2) Ejemplos de datasets disponibles

Algunos ejemplos de datasets disponibles con información de ventas de supermercado.

Search

- Home
- Competitions
- Datasets
- Code
- Discussions
- Courses
- More

Dataset

Groceries Market Basket Dataset

The dataset contains 9835 transactions and 169 unique items.

Irfan Nasrullah • updated 3 years ago (Version 2)

[Data](#)
[Code \(26\)](#)
[Discussion](#)
[Activity](#)
[Metadata](#)

Usability 8.2

License Data files © Original Author

Description

Context
The Groceries Market Basket Dataset, which can be found [here](#). The dataset contains 9835 transactions and 169 unique items.

The data is suitable to do data mining for market basket analysis which has many applications.

groceries - groceries.csv (802.87 kB)

About this file

This is the groceries data with the list of items bought by customers. From the left side is the number of items in a basket then Item 1, 2, 3, etc stands for list of the item. If you think can improve or just to make sure about the data just leave some words in the comment section below.

# Item(s)	Item 1	Item 2	Item 3	Item 4
1	sausage 8%	[null] 22%	[null] 39%	[null] 52%
	whole milk 7%	whole milk 7%	whole milk 5%	whole milk 3%
	Other (8293) 84%	Other (7022) 71%	Other (5527) 56%	Other (4419) 45%
4	citrus fruit	semi-finished bread	margarine	ready soups
3	tropical fruit	yogurt	coffee	
1	whole milk			
4	pip fruit	yogurt	cream cheese	meat spreads
4	other vegetables	whole milk	condensed milk	long life bakery product

Etapas

1. Determinación de las fuentes de los datos.

- Capturar/Extraer los datos. ¿Qué está disponible?
- Almacenar los datos.



2. Exploración y pre-procesado de los datos → Prepararlos.

- Investigación preliminar de los datos para comprender sus características.
- Limpiar los datos para obtener un conjunto de datos de calidad.
- Manipular los datos para que estén en el formato necesario para su posterior uso.

3. Procesado y análisis de los datos.

- Elección de una técnica para analizar los datos.
- Elaboración de un modelo a partir de los datos disponibles.
- Validar el modelo (conjuntos de prueba o nuevos datos).

Etapas

1. Determinación de las fuentes de los datos.

- Capturar/Extraer los datos. ¿Qué está disponible?
- Almacenar los datos.



2. Exploración y pre-procesado de los datos → Prepararlos.

- Investigación preliminar de los datos para comprender sus características.
- Limpiar los datos para obtener un conjunto de datos de calidad.
- Manipular los datos para que estén en el formato necesario para su posterior uso.

3. Procesado y análisis de los datos.

- Elección de una técnica para analizar los datos.
- Elaboración de un modelo a partir de los datos disponibles.
- Validar el modelo (conjuntos de prueba o nuevos datos).

4. Comunicación de los resultados.

- Presentar los resultados y las conclusiones (*storytelling, reporting, data visualization*, etc). Conclusiones que disparen decisiones (*data-driven*).

Etapas

1. Determinación de las fuentes de los datos.

- Capturar/Extraer los datos. ¿Qué está disponible?
- Almacenar los datos.



2. Exploración y pre-procesado de los datos → Prepararlos.

- Investigación preliminar de los datos para comprender sus características.
- Limpiar los datos para obtener un conjunto de datos de calidad.
- Manipular los datos para que estén en el formato necesario para su posterior uso.

3. Procesado y análisis de los datos.

- Elección de una técnica para analizar los datos.
- Elaboración de un modelo a partir de los datos disponibles.
- Validar el modelo (conjuntos de prueba o nuevos datos).

4. Comunicación de los resultados.

- Presentar los resultados y las conclusiones (*storytelling, reporting, data visualization*, etc). Conclusiones que disparen decisiones (*data-driven*).

5. Ejecución de las decisiones tomadas.

- Transformar en conocimiento en acción. Controlar el plan ejecutado.

(3) Análisis de datos: el modelo

Se trata de un problema de **Asociación**, donde se pretende encontrar patrones ocultos a través de reglas que permiten determinar cuando una serie de eventos ocurren juntos.

Este caso en particular se trata de un análisis de canastas de mercado o carritos de compra, con el fin de obtener *insights* sobre el comportamiento de los clientes.

Se parte de un conjunto de n transacciones, con m artículos o ítems cada una (a modo de ejemplo, se ejemplificará con 5 transacciones y hasta 4 ítems por compra):

Transacción	Items			
1	Pañales	Pan	Leche	-
2	Pan	Pañales	Cerveza	Huevos
3	Leche	Pañales	Cerveza	Manteca
4	Pan	Leche	Pañales	Cerveza
5	Pan	Leche	Pañales	Manteca

(3) Análisis de datos: el modelo

1. Crear sets de ítems

El primer paso de este algoritmo consiste en establecer sets o conjuntos de ítems/productos. Por ejemplo, un set podría ser **{Pañales}**, otro podría ser **{Pan, Leche}**.

En este ejemplo se cuenta con 6 artículos distintos, por lo que pueden plantearse 6 sets de un ítem cada uno.

1º Set de ítems

Sets de ítem	Support
[Cerveza]	3/5 --> 0,6
[Huevos]	1/5 --> 0,2
[Leche]	4/5 --> 0,8
[Manteca]	2/5 --> 0,4
[Pan]	4/5 --> 0,8
[Pañales]	5/5 --> 1

2. Identificar los sets de ítems más frecuentes

Para ello se utiliza el *Support*. Esta medida establece para cada set de ítems la frecuencia relativa de ese set en particular dentro del conjunto total de transacciones.

$$\text{Support}(X) = \frac{\text{Cantidad de transacción con el ítem } X}{\text{Cantidad total de transacciones}}$$

(3) Análisis de datos: el modelo

Para ello se establece un *Support* mínimo, de modo tal que aquellos sets de ítems que tengan un valor inferior a mínimo se descartan.
Por ejemplo, con un valor de ⅓ se descartan los siguientes sets de 1, 2 y 3 ítems (coloreados en rojo).

Transacción	Items			
1	Pañales	Pan	Leche	-
2	Pan	Pañales	Cerveza	Huevos
3	Leche	Pañales	Cerveza	Manteca
4	Pan	Leche	Pañales	Cerveza
5	Pan	Leche	Pañales	Manteca

3º Set de items	
Sets de ítem	Support
[Pan, Leche, Pañales]	3/5 --> 0,6

1º Set de items	
Sets de ítem	Support
[Cerveza]	3/5 --> 0,6
[Huevos]	1/5 --> 0,2
[Leche]	4/5 --> 0,8
[Manteca]	2/5 --> 0,4
[Pan]	4/5 --> 0,8
[Pañales]	5/5 --> 1

2º Set de items	
Sets de ítem	Support
[Pan, Leche]	3/5 --> 0,6
[Pan, Cerveza]	2/5 --> 0,4
[Pan, Pañales]	4/5 --> 0,8
[Leche, Cerveza]	2/5 --> 0,4
[Leche, Pañales]	4/5 --> 0,8
[Cerveza, Pañales]	3/5 --> 0,6

(3) Análisis de datos: el modelo

3. Crear reglas de asociación con estos sets de ítems frecuentes

Los sets de ítems resultantes del paso 2 son los siguientes:

1º Set de ítems		2º Set de ítems		3º Set de ítems	
Sets de ítem	Support	Sets de ítem	Support	Sets de ítem	Support
[Cerveza]	3/5	[Pan, Leche]	3/5	[Pan, Leche, Pañales]	3/5
[Leche]	4/5	[Pan, Pañales]	4/5		
[Pan]	4/5	[Leche, Pañales]	4/5		
[Pañales]	5/5	[Cerveza, Pañales]	3/5		

Estas reglas tienen la siguiente estructura, con X e Y siendo sets de ítems. Las mismas se leen “Si X, entonces Y”:

$$X \Rightarrow Y ;$$

X = Antecedente; Y = Consecuente

Por ejemplo, la regla **{Pañales} => {Cerveza}** representa que si se compra pañales, entonces también se compra cerveza.

(3) Análisis de datos: el modelo

Para determinar la fiabilidad de una regla de asociación se recurre a una medida denominada *Confianza* o *Confidence*. Esta mide la frecuencia con la que aparecen los artículos Y en las transacciones que contienen artículos X .

$$Confidence (X \rightarrow Y) = \frac{Support(X \cup Y)}{Support (X)}$$

Para restringir la cantidad de reglas a mantener, se utiliza un umbral mínimo de confianza:

- Sólo aquellas reglas de asociación con una confianza mayor a este umbral mínimo se consideran significativas y se conservarán para el análisis.

A continuación se presentan 2 ejemplos de su cálculo, fijando un nivel de confianza del 95%.

(3) Análisis de datos: el modelo

2º Set de items

Sets de ítem	Support
[Pan, Leche]	3/5
[Pan, Pañales]	4/5
[Leche, Pañales]	4/5
[Cerveza, Pañales]	3/5

Regla de Asociación candidata: {Pan, Leche} → {Pañales}

$$\begin{aligned}\text{Confidence}(\{Pan, Leche\} \rightarrow \{Pañales\}) &= \frac{\text{Support}(Pan, Leche, Pañales)}{\text{Support}(Pan, Leche)} \\ &= \frac{3/5}{3/5} = \underline{\underline{1}}\end{aligned}$$

En este caso la confianza de la regla es del 100%, es decir que cada vez que se compra pan y leche, también se compra pañales.

2º Set de items

Sets de ítem	Support
[Pan, Leche]	3/5
[Pan, Pañales]	4/5
[Leche, Pañales]	4/5
[Cerveza, Pañales]	3/5

Regla de Asociación candidata: {Pan, Pañales} → {Leche}

$$\begin{aligned}\text{Confidence}(\{Pan, Pañales\} \rightarrow \{Leche\}) &= \frac{\text{Support}(Pan, Pañales, Leche)}{\text{Support}(Pan, Pañales)} \\ &= \frac{3/5}{4/5} = \frac{3}{4} = \underline{\underline{0,75}} \text{ o } 75\%\end{aligned}$$

En este caso, al fijarse un nivel mínimo de confianza del 95%, la regla candidata es descartada.

(3) Análisis de datos: el modelo




Dado que cada ítem en un set de ítems puede utilizarse como antecedente o como consecuente de la regla, utilizar fuerza bruta para determinar las reglas de asociación es computacionalmente prohibitivo.

1º Set de ítems		Posibles reglas
Sets de ítem	Support	
[Cerveza]	3/5	0
[Leche]	4/5	0
[Pan]	4/5	0
[Pañales]	5/5	0

2º Set de ítems		Posibles reglas
Sets de ítem	Support	
[Pan, Leche]	3/5	2
[Pan, Pañales]	4/5	2
[Leche, Pañales]	4/5	2
[Cerveza, Pañales]	3/5	2

3º Set de ítems		Posibles reglas
Sets de ítem	Support	
[Pan, Leche, Pañales]	3/5	6



Dados d únicos ítems:

- Total de sets de ítems posibles: 2^d
- Total de posibles reglas de asociación:

$$R = \sum_{k=1}^{d-1} \left[\binom{d}{k} \times \sum_{j=1}^{d-k} \binom{d-k}{j} \right]$$
$$= 3^d - 2^{d+1} + 1$$

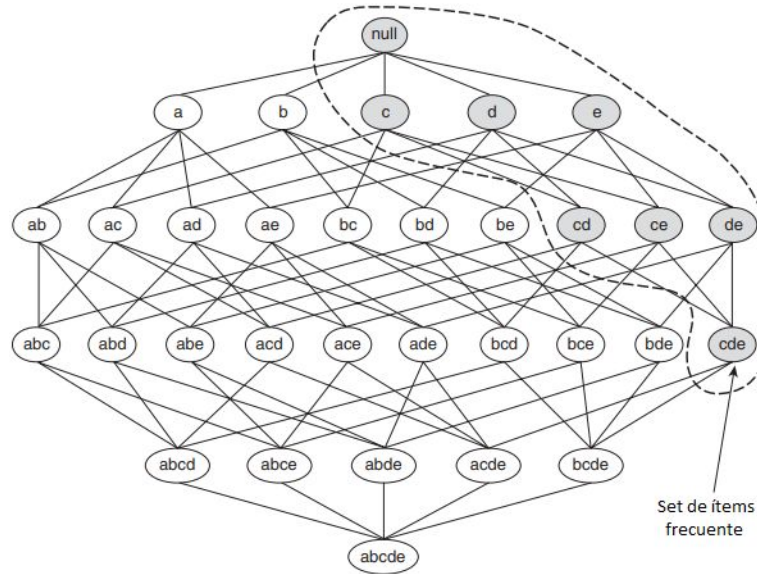
Fuente: Introduction to Data Mining - 2º edition

(3) Análisis de datos: el modelo

Para reducir el número de sets de ítems candidatos, y por lo tanto la cantidad de reglas de asociación candidatas, se recurre a diversos algoritmos.

En particular el siguiente teorema, conocido como **Principio Apriori**, establece:

“Si un set de ítems es frecuente, entonces todos sus subsets son frecuentes”.



Representación del Principio Apriori.

(3) Análisis de datos: el modelo

El **Factor de Interés**, o **Lift**, mide la proporción entre la confianza de una regla y la confianza esperada para el producto consecuente.

$$I(A, B) = \frac{s(A, B)}{s(A) \times s(B)} = \frac{N f_{11}}{f_{1+} f_{+1}}.$$

Por ejemplo, para la regla $\{Pañales\} \rightarrow \{Leche\}$, resulta:

$$Lift(\{Pañales\} \rightarrow \{Leche\}) = \frac{Support(\{Pañales, Leche\})}{Support(\{Pañales\}) \times Support(\{Leche\})} = \frac{0,8}{1 \times 0,8} = 1$$

$$Lift(\{Pañales\} \rightarrow \{Leche\}) = \frac{Confidence(\{Pañales\} \rightarrow \{Leche\})}{Cantidad(\{Leche\}) / Transacciones} = \frac{0,8}{4/5} = 1$$

De esta medida se puede concluir lo siguiente:

$$I(A, B) \begin{cases} = 1, & \text{if } A \text{ and } B \text{ are independent;} \\ > 1, & \text{if } A \text{ and } B \text{ are positively related;} \\ < 1, & \text{if } A \text{ and } B \text{ are negatively related.} \end{cases}$$

(3) Análisis de datos: el modelo

Existe una gran cantidad de medidas propuestas para estimar la bondad de una regla de asociación. Algunos ejemplos:

#	Measure	Formula
1	ϕ -coefficient	$\frac{P(A,B) - P(A)P(B)}{\sqrt{P(A)P(B)(1-P(A))(1-P(B))}}$
2	Goodman-Kruskal's λ	$\frac{\sum_j \max_k P(A_j, B_k) + \sum_k \max_j P(A_j, B_k) - \max_j P(A_j) - \max_k P(B_k)}{2 - \max_j P(A_j) - \max_k P(B_k)}$
3	Odds ratio $\langle \alpha \rangle$	$\frac{P(A,B)P(\bar{A},\bar{B})}{P(A,\bar{B})P(\bar{A},B)}$
4	Yule's Q	$\frac{P(A,B)P(\bar{A}\bar{B}) - P(A,\bar{B})P(\bar{A},B)}{P(A,B)P(\bar{A}\bar{B}) + P(A,\bar{B})P(\bar{A},B)} = \frac{\alpha - 1}{\alpha + 1}$
5	Yule's Y	$\frac{\sqrt{P(A,B)P(\bar{A}\bar{B})} - \sqrt{P(A,\bar{B})P(\bar{A},B)}}{\sqrt{P(A,B)P(\bar{A}\bar{B})} + \sqrt{P(A,\bar{B})P(\bar{A},B)}} = \frac{\sqrt{\alpha} - 1}{\sqrt{\alpha} + 1}$
6	Kappa $\langle \kappa \rangle$	$\frac{P(A,B) + P(\bar{A},\bar{B}) - P(A)P(B) - P(\bar{A})P(\bar{B})}{1 - P(A)P(B) - P(\bar{A})P(\bar{B})}$
7	Mutual Information $\langle M \rangle$	$\frac{\sum_i \sum_j P(A_i, B_j) \log \frac{P(A_i, B_j)}{P(A_i)P(B_j)}}{\min(-\sum_i P(A_i) \log P(A_i), -\sum_j P(B_j) \log P(B_j))}$
8	J-Measure $\langle J \rangle$	$\max \left(P(A, B) \log \left(\frac{P(A B)}{P(A)} \right) + P(\bar{A}, \bar{B}) \log \left(\frac{P(\bar{B} \bar{A})}{P(\bar{B})} \right), \right.$ $\left. P(A, B) \log \left(\frac{P(A B)}{P(A)} \right) + P(\bar{A}, \bar{B}) \log \left(\frac{P(\bar{A} \bar{B})}{P(\bar{A})} \right) \right)$
9	Gini index $\langle G \rangle$	$\max \left(P(A)[P(B A)^2 + P(\bar{B} A)^2] + P(\bar{A})[P(B \bar{A})^2 + P(\bar{B} \bar{A})^2] \right.$ $\left. - P(B)^2 - P(\bar{B})^2, \right.$ $\left. P(B)[P(A B)^2 + P(\bar{A} B)^2] + P(\bar{B})[P(A \bar{B})^2 + P(\bar{A} \bar{B})^2] \right.$ $\left. - P(A)^2 - P(\bar{A})^2 \right)$
10	Support $\langle s \rangle$	$P(A, B)$
11	Confidence $\langle c \rangle$	$\max(P(B A), P(A B))$
12	Laplace $\langle L \rangle$	$\max \left(\frac{NP(A,B)+1}{NP(A)+2}, \frac{NP(A,B)+1}{NP(B)+2} \right)$
13	Conviction $\langle V \rangle$	$\max \left(\frac{P(A)P(\bar{B})}{P(A\bar{B})}, \frac{P(B)P(\bar{A})}{P(\bar{A}B)} \right)$
14	Interest $\langle I \rangle$	$\frac{P(A,B)}{P(A)P(B)}$
15	cosine $\langle IS \rangle$	$\frac{P(A,B)}{\sqrt{P(A)P(B)}}$
16	Piatetsky-Shapiro's $\langle PS \rangle$	$P(A, B) - P(A)P(B)$
17	Certainty factor $\langle F \rangle$	$\max \left(\frac{P(B A) - P(B)}{1 - P(B)}, \frac{P(A B) - P(A)}{1 - P(A)} \right)$
18	Added Value $\langle AV \rangle$	$\max(P(B A) - P(B), P(A B) - P(A))$
19	Collective strength $\langle S \rangle$	$\frac{P(A,B) + P(\bar{A}\bar{B})}{P(A)P(B) + P(\bar{A})P(\bar{B})} \times \frac{1 - P(A)P(B) - P(\bar{A})P(\bar{B})}{1 - P(A,B) - P(\bar{A}\bar{B})}$
20	Jaccard $\langle \zeta \rangle$	$\frac{P(A,B)}{P(A) + P(B) - P(A,B)}$
21	Kloggen $\langle K \rangle$	$\sqrt{P(A, B) \max(P(B A) - P(B), P(A B) - P(A))}$

Fuente: Introduction to Data Mining - 2° edition

(3) Análisis de datos: el modelo

Algoritmo Apriori para generar sets de ítems.

Algorithm 5.1 Frequent itemset generation of the *Apriori* algorithm.

```
1:  $k = 1$ .
2:  $F_k = \{ i \mid i \in I \wedge \sigma(\{i\}) \geq N \times \text{minsup} \}$ .    {Find all frequent 1-itemsets}
3: repeat
4:    $k = k + 1$ .
5:    $C_k = \text{candidate-gen}(F_{k-1})$ .    {Generate candidate itemsets.}
6:    $C_k = \text{candidate-prune}(C_k, F_{k-1})$ .    {Prune candidate itemsets.}
7:   for each transaction  $t \in T$  do
8:      $C_t = \text{subset}(C_k, t)$ .    {Identify all candidates that belong to  $t$ .}
9:     for each candidate itemset  $c \in C_t$  do
10:       $\sigma(c) = \sigma(c) + 1$ .    {Increment support count.}
11:   end for
12: end for
13:  $F_k = \{ c \mid c \in C_k \wedge \sigma(c) \geq N \times \text{minsup} \}$ .    {Extract the frequent  $k$ -itemsets.}
14: until  $F_k = \emptyset$ 
15:  $\text{Result} = \bigcup F_k$ .
```

(*) Cervezas y pañales

DSS News

D. J. Power, Editor

November 10, 2002 -- Vol. 3, No. 23

A Bi-Weekly Publication of DSSResources.COM

What is the "true story" about using data mining to identify a relation between sales of beer and diapers?

This is one of those recurring questions related to a famous decision support example... The following are some versions of the tale ...

An article in The Financial Times of London (Feb. 7, 1996) stated, "The oft-quoted example of what data mining can achieve is the case of a large US supermarket chain which discovered an association for many customers between a brand of beer (diapers) and a brand of beer. Most customers who bought the beer also bought the beer. The best hypothesis is that it is difficult to propose this combination. The retail outlet showed it existed, and the retail outlet was moving the products closer together on the shelves."

Bill Palace at UCLA (Spring 1996) in his example, one Midwest grocery chain used the capacity of Oracle software to analyze local sales data. He discovered that when men bought diapers, they also tended to buy beer. Further analysis showed that typically did their weekly grocery shopping on Thursdays, however, they only bought a six-pack of beer on the upcoming weekend. The grocery chain could use this information in various ways to increase revenue: move the beer display closer to the diaper display, or ensure beer and diapers were sold at full price.

Hermiz and Manganaris (1999) stated "One of the (though likely fabricated) data mining stories is that beer and diapers frequently appear together in market baskets. The explanation goes that when fathers are out shopping for diapers, they often purchase a six-pack of beer as well."

So what are the facts? In 1992, Thomas Blischok, manager of a retail consulting group at Teradata, and his staff prepared an analysis of 1.2 million market baskets from about 25 Osco Drug stores. Database queries were developed to identify affinities. The analysis "did discover that between 5:00 and 7:00 p.m. that consumers bought beer and diapers". Osco managers did NOT exploit the beer and diapers relationship by moving the products closer together on the shelves. This decision support study was conducted using query tools to find an association. The true story is very bland compared to the legend.

So if someone asks you about the story of "data mining, beer and diapers" you now know the facts. The story most people tell is fiction and legend. You can continue telling the story, but remember no matter how you tell it, the story of "data mining, beer and diapers" is NOT a good example of the possibilities for decision support with current data mining technologies.

Forbes

Apr 6, 1998 12:00am EDT

Diaper-beer syndrome



Follow

This article is more than 10 years old.

IT'S PART OF the folklore of data processing. A retail chain put all its checkout-counter data into a giant digital warehouse and set the disk drives spinning.

Out popped a most unexpected correlation: sales of diapers and beer.

...e-night run to the store to pick up what they were there.

...iced the disparate items together.

...see box). But that didn't stop it from becoming a software: telling corporations how to set up their "tons of transaction data," said the "valuable insights into your customers,

...metimes. Empire Blue Cross and Blue Cross are among those that have mined the data, but it doesn't work.

Gracias!

Ante cualquier inquietud: valentinsilvestri@outlook.com